Contrôle adaptatif d'un carrefour isolé par Double DQN : évaluation multi-graines et analyse de Max-Pressure sous SUMO

Mamadou Ahmadou Ka

Département Informatique, UFR Sciences et Technologies
Université Iba Der Thiam de Thiès (UIDT), Thiès, Sénégal
mahmadou.ka@univ-thies.sn

Résumé

La régulation adaptative des feux de circulation (*Adaptive Traffic Signal Control*, ATSC) vise à ajuster dynamiquement l'allocation des temps de vert aux variations locales de la demande de trafic. Cet article présente une évaluation expérimentale d'un agent décisionnel fondé sur l'apprentissage par renforcement profond (*Double Deep Q-Network*, DDQN) face à trois familles de contrôleurs : le plan fixe d'origine du réseau (cycle de 78 s), un régulateur actionné par détection de lacune (*actuated gap-out*) et la règle heuristique Max-Pressure (Varaiya, 2013). Les expérimentations sont conduites sous le simulateur microscopique Eclipse SUMO sur une modélisation du carrefour principal de Thiès (Sénégal), dérivée de données OpenStreetMap. L'évaluation repose sur cinq graines stochastiques indépendantes, simulées chacune pendant 3600 s (1 heure de trafic continu). Les résultats montrent que l'agent Double DQN réduit le temps perdu moyen (*timeLoss*) de 50,7 % (15,5 $\pm$ 0,6 s contre 31,5 $\pm$ 0,5 s pour le plan fixe) et le temps d'attente à l'arrêt à 9,0 $\pm$ 0,5 s (contre 23,8 $\pm$ 0,4 s), avec un débit d'évacuation stable compris entre 840 et 890 véhicules terminés ($\approx$ 889). L'algorithme actionné enregistre un retard moyen de 34,2 $\pm$ 1,1 s (+8,7 % par rapport au plan fixe). Par ailleurs, un diagnostic microscopique conduit sur la graine 7 met en évidence le mécanisme de dégradation de la variante naïve de Max-Pressure (somme des files) : l'algorithme n'effectue que 91 commutations de phase (écartant l'hypothèse d'une instabilité de commutation ou *thrashing*), mais alloue 80,8 % du temps vert à la Phase 2 et 0 % à la Phase 3. Cette famine de phase provoque la saturation de l'approche secondaire et un refoulement amont (*spillback*) bloquant l'insertion de 207 véhicules sur le réseau, ce qui abaisse le débit achevé à environ 580 véhicules. À l'inverse, l'agent Double DQN alloue 18,3 % du temps vert à la Phase 3, assurant la purge régulière des files secondaires et prévenant tout blocage d'insertion.

Mots-clés : Systèmes de transport intelligents, régulation des feux de circulation, apprentissage par renforcement profond, Double DQN, Max-Pressure, famine de phase, Eclipse SUMO.

1. Introduction

La gestion des intersections routières constitue un levier majeur d'optimisation de la fluidité dans les réseaux urbains. Dans les agglomérations à forte croissance démographique où le maillage viaire offre peu d'itinéraires alternatifs, comme à Thiès (Sénégal), les carrefours à niveau concentrent l'essentiel des retards et des files d'attente [1].

La régulation de ces carrefours s'appuie traditionnellement sur des plans à temps fixe (*Fixed-Time*), dont les temporisations sont calées sur des moyennes historiques. Bien que robustes et simples d'exploitation, ces plans statiques ne s'adaptent pas aux fluctuations temporelles et aux asymétries de charge ponctuelles. Par ailleurs, les systèmes industriels adaptatifs coordonnés (tels que SCATS [3] ou SCOOT [4]) requièrent des infrastructures lourdes (boucles électromagnétiques sous chaussée, réseaux filaires dédiés) et des coûts de maintenance souvent difficilement soutenables pour les collectivités locales de pays émergents.

Dans ce contexte, l'apprentissage par renforcement profond (*Deep Reinforcement Learning*, DRL) offre un cadre pour concevoir des contrôleurs locaux capables d'ajuster les feux à partir d'observations directes de l'état du trafic [5, 6, 7, 8]. Cependant, plusieurs revues de la littérature soulignent des lacunes méthodologiques récurrentes dans les travaux du domaine [9, 10]. Les évaluations se limitent fréquemment à une comparaison avec le seul plan fixe, sans confrontation aux régulateurs actionnés ni aux heuristiques fondées de la recherche en transport, en premier lieu l'algorithme Max-Pressure formulé par Varaiya [12]. En outre, l'analyse des résultats se restreint souvent à l'évolution de la courbe de récompense, sans examen approfondi du comportement microscopique des politiques (durées effectives de vert, fréquence des commutations, détection de famines de mouvements). Enfin, de nombreuses études recourent à des grilles synthétiques symétriques, qui masquent les difficultés propres aux carrefours asymétriques réels.

Le présent travail étudie le contrôle adaptatif d'une intersection isolée réelle modélisée sous Eclipse SUMO. Nous formulons le problème sous la forme d'un Processus de Décision Markovien (MDP) compact à 13 dimensions, avec une fonction de récompense différentielle fondée sur la variation du temps d'attente cumulé. Un agent Double DQN muni d'un masque de contraintes de sécurité (vert minimal, vert maximal, jaune intermédiaire) est entraîné puis évalué sur cinq graines stochastiques indépendantes face au plan fixe d'origine du réseau, à un régulateur actionné par détection de lacune et à deux variantes de Max-Pressure. Nous analysons ensuite les mécanismes comportementaux sous-jacents, en caractérisant

le phénomène de famine de phase observé sur la variante naïve de Max-Pressure.

L'article est structuré comme suit. La section 2 présente l'état de l'art. La section 3 expose la modélisation du carrefour, de Max-Pressure et du MDP. La section 4 détaille l'agent Double DQN. La section 5 décrit le protocole expérimental sous SUMO. La section 6 présente les résultats comparatifs et le diagnostic microscopique. La section 7 discute les apports, limites et perspectives. La section 8 conclut l'étude.

2. État de l'art

2.1. Approches conventionnelles et heuristiques de transport

La méthode de Webster [2] demeure la référence théorique pour le dimensionnement des cycles de feux à temps fixe à partir des débits moyens observés. En pratique dynamique, la régulation actionnée (*Actuated Control*) ajuste la durée du vert par détection locale de présence de véhicules : tant que l'intervalle temporel entre véhicules successifs reste inférieur à un seuil critique (Δt_{gap}), le vert est maintenu dans la limite d'un plafond $g_{\max}$ [11].

L'algorithme Max-Pressure, développé par Varaiya [12] et approfondi par Lioris *et al.* [13], fournit une règle de contrôle décentralisée assurant la stabilité d'un réseau de carrefours sous l'hypothèse de modèles continus dits *store-and-forward*. En sélectionnant à chaque pas de décision la phase qui maximise le différentiel de files d'attente entre voies amont et voies aval, l'algorithme garantit que les files restent bornées dès lors que la demande demeure dans la région de capacité admissible. Toutefois, les propriétés asymptotiques de Max-Pressure reposent sur des hypothèses continues et un réseau maillé ; sur un carrefour isolé asymétrique avec des files discrètes, l'agrégation non normalisée des files peut introduire des biais en faveur des axes les plus capacitaires.

2.2. Apprentissage par renforcement profond

L'essor des méthodes de Deep Q-Network (DQN) [14] a conduit à leur application au contrôle de feux de circulation [15]. IntelliLight [5] a mis en avant l'intérêt d'un vecteur d'état continu combinant longueurs de files, densités et positions de véhicules à l'arrêt, surpassant les régulateurs classiques sur des données de carrefours réels.

Plusieurs contributions ont cherché à relier le DRL aux principes de la théorie du trafic. PressLight [6] intègre la notion de pression dans la fonction de récompense de l'agent afin d'orienter l'apprentissage vers la stabilité du réseau. MPLight [7] combine Max-Pressure et factorisation d'état pour le contrôle coordonné à l'échelle de grands réseaux. PD-Light [8] modifie l'indicateur de pression en prenant en compte la capacité résiduelle des voies d'évacuation aval (*PRCOL*) afin de prévenir les blocages par refoulement. Les revues de synthèse récentes [9, 10] confirment la pertinence des variantes DQN en environnement microscopique (SUMO, CityFlow), tout en appelant à des évaluations plus complètes face aux baselines de transport.

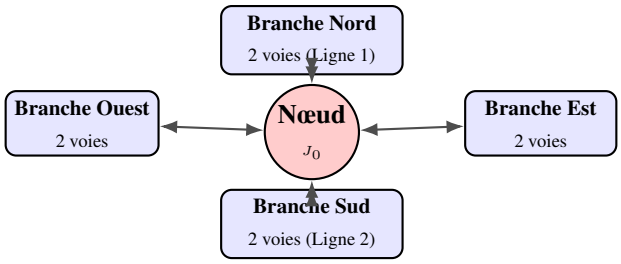


FIGURE 1 – Schéma de principe du carrefour modélisé sous SUMO (4 branches d'accès de 2 voies chacune).

2.3. Positionnement du travail

Le présent travail s'inscrit dans la lignée des approches Deep RL appliquées à un carrefour isolé. Contrairement à PressLight, nous ne cherchons pas à optimiser une fonction de récompense formulée en termes de pression, mais une variation de temps d'attente cumulé (ΔW). L'algorithme Max-Pressure est ici mobilisé comme une référence de comparaison expérimentale, et non comme un objet théorique à invalider. Notre objectif est de caractériser de façon empirique et microscopique le comportement respectif de ces deux approches sur une géométrie asymétrique issue du terrain.

3. Formulation du problème

3.1. Topologie de l'intersection et phases

Nous considérons une intersection isolée à niveau à quatre branches d'accès issue du carrefour principal de Thiès (Sénégal). Le carrefour comprend 8 voies d'entrée amont $\mathcal{L}_{\text{in}} = \{l_1, \ldots, l_8\}$ (deux voies par branche) et 8 voies de sortie aval $\mathcal{L}_{\text{out}}$ (Figure 1). Un mouvement de trafic $m = (l, l')$ désigne une trajectoire autorisée reliant une voie entrante $l \in \mathcal{L}_{\text{in}}$ à une voie sortante $l' \in \mathcal{L}_{\text{out}}$.

Le carrefour est contrôlé par quatre phases de feux verts non conflictuelles notées $\mathcal{P} = \{p_0, p_1, p_2, p_3\}$:

- **Phase 0 :** circulation directe sur l'axe principal (Nord-Sud) ;
- **Phase 1 :** mouvements de tourne-à-gauche protégés sur l'axe principal ;
- **Phase 2 :** circulation directe sur l'axe secondaire (Est-Ouest) ;
- **Phase 3 :** mouvements de tourne-à-gauche protégés sur l'axe secondaire.

Toute transition entre deux phases distinctes est précédée d'un feu jaune de sécurité d'une durée fixe de $y = 3\,\text{s}$.

3.2. Formulation de Max-Pressure en carrefour isolé

Pour une intersection isolée dont les voies aval $\mathcal{L}_{\text{out}}$ ne subissent pas de congestion induite par un carrefour voisin, la

pression $P_m(t)$ d'un mouvement m correspond au nombre de véhicules arrêtés $x_l(t)$ sur sa voie d'entrée d'origine l :

$$P_m(t) = x_l(t), \quad \forall m = (l, l'). \tag{1}$$

La pression globale d'une phase candidate $p \in \mathcal{P}$ est calculée sur l'ensemble de ses mouvements autorisés $\mathcal{M}(p)$ selon deux modes d'agrégation :

$$\text{Mode Somme (MP-Sum)} : P_{\text{sum}}(p,t) = \sum_{m \in \mathcal{M}(p)} x_{l(m)}(t), \tag{2}$$

$$\text{Mode Maximum (MP-Max)} : P_{\max}(p,t) = \max_{m \in \mathcal{M}(p)} x_{l(m)}(t). \tag{3}$$

À chaque pas de décision, l'action sélectionnée par Max-Pressure est définie par :

$$a^*_{\text{MP}}(t) = \arg\max_{p \in \mathcal{A}_{\text{valid}}(t)} P(p,t), \tag{4}$$

où $\mathcal{A}_{\text{valid}}(t)$ restreint le choix des actions afin de satisfaire le temps de vert minimal ($g_{\min} = 10\,\text{s}$) et le plafond maximal ($g_{\max} = 60\,\text{s}$).

3.3. Processus de Décision Markovien

Le problème de régulation est modélisé sous la forme d'un Processus de Décision Markovien défini par le quintuplet $\langle \mathcal{S}, \mathcal{A}, \mathcal{P}_{ss'}, \mathcal{R}, \gamma \rangle$:

Espace des états $\mathcal{S} \subset \mathbb{R}^{13}$. Le vecteur d'observation $\mathbf{s}_t \in \mathbb{R}^{13}$ capturé à l'instant de décision t est composé de quatre composantes normalisées :

$$\mathbf{s}_t = \left[\mathbf{q}_t^\top,\, \mathbf{k}_t^\top,\, \mathbf{e}_t^\top,\, \delta_t\right]^\top, \tag{5}$$

où $\mathbf{q}_t = [q_0, q_1, q_2, q_3]^\top \in [0,1]^4$ regroupe les longueurs de file normalisées sur les 4 branches d'accès (somme des voies par approche), calculées par $q_i = \min(n_{\text{stop},i}/Q_{\max}, 1{,}0)$ avec un seuil de référence $Q_{\max} = 10{,}0$ véhicules arrêtés ($v < 0{,}1\,\text{m/s}$) ; $\mathbf{k}_t = [k_0, k_1, k_2, k_3]^\top \in [0,1]^4$ représente les densités moyennes normalisées par approche ; $\mathbf{e}_t \in \{0,1\}^4$ est l'encodage binaire (*One-Hot*) de la phase verte en cours ($e_j = 1$ si la phase j est active) ; et $\delta_t \in \{0,1\}$ est un indicateur de garde de sécurité valant 1 si la phase active a atteint son vert minimal ($t_{\text{green}} \geq g_{\min}$), autorisant un changement de phase, et 0 sinon.

Espace des actions $\mathcal{A}$. Les actions possibles correspondent aux indices des phases de feux autorisées :

$$\mathcal{A} = \{0, 1, 2, 3\}. \tag{6}$$

Choisir l'action $a_t = p$ commande à l'automate de maintenir la phase p ou d'engager la transition jaune de 3 s vers p si $a_t \neq a_{t-1}$.

Fonction de récompense $\mathcal{R}$. La récompense r_t associée à la transition d'état est définie par la variation du temps d'attente cumulé global $W(t)$ sur le carrefour :

$$r_t = \frac{W(t) - W(t + \Delta t)}{100{,}0}, \tag{7}$$

où $W(t) = \sum_{v \in \mathcal{V}(t)} w_v(t)$ est la somme des temps d'attente individuels de tous les véhicules présents dans le réseau au pas t. Une diminution du temps d'attente global ($W(t+\Delta t) < W(t)$) produit une récompense positive. Le coût temporel induit par les transitions jaunes est naturellement répercuté : la fermeture temporaire des voies engendre une augmentation transitoire de $W(t)$, ce qui réduit la valeur de la récompense sans qu'il soit nécessaire d'introduire une pénalité arbitraire.

4. Agent Double DQN

4.1. Principe de l'algorithme

Dans le Q-learning standard, l'utilisation conjointe du même réseau pour la sélection de l'action optimale et l'évaluation de sa valeur cible conduit fréquemment à une surestimation des valeurs Q en milieu stochastique. L'algorithme Double DQN [16] découple ces deux opérations en utilisant le réseau principal pour déterminer l'action maximisante et le réseau cible pour en évaluer la valeur :

$$Y_t^{\text{DoubleQ}} = r_t + \gamma\, Q\big(\mathbf{s}_{t+1},\, \arg\max_{a'} Q(\mathbf{s}_{t+1}, a'; \boldsymbol{\theta}_t);\, \boldsymbol{\theta}_t^-\big), \tag{8}$$

où $\boldsymbol{\theta}_t$ désigne les paramètres du réseau principal et $\boldsymbol{\theta}_t^-$ ceux du réseau cible.

L'apprentissage repose sur la minimisation de la perte de Huber (*smooth L1 loss*), plus robuste face aux variations brutales de récompense que la perte quadratique moyenne :

$$\mathcal{L}(\boldsymbol{\theta}) = \mathbb{E}_{(\mathbf{s},a,r,\mathbf{s}') \sim \mathcal{D}}\left[\ell_{\text{Huber}}\big(Y^{\text{DoubleQ}} - Q(\mathbf{s}, a; \boldsymbol{\theta})\big)\right], \tag{9}$$

à partir d'un tampon d'expérience $\mathcal{D}$ d'une capacité de 50 000 transitions. Le réseau cible est actualisé de manière progressive (*soft update*) à chaque pas de mise à jour selon $\boldsymbol{\theta}^- \leftarrow \tau\boldsymbol{\theta} + (1-\tau)\boldsymbol{\theta}^-$, avec un taux $\tau = 0{,}005$.

4.2. Architecture neuronale et masquage d'actions

Le réseau de valeur $Q(\mathbf{s}, a; \boldsymbol{\theta})$ est paramétré par un perceptron multicouche comprenant deux couches cachées de 64 neurones chacune, avec des activations ReLU :

$$\mathbf{h}_1 = \text{ReLU}(\mathbf{W}_1\mathbf{s} + \mathbf{b}_1), \quad \mathbf{W}_1 \in \mathbb{R}^{64\times 13}, \tag{10}$$

$$\mathbf{h}_2 = \text{ReLU}(\mathbf{W}_2\mathbf{h}_1 + \mathbf{b}_2), \quad \mathbf{W}_2 \in \mathbb{R}^{64\times 64}, \tag{11}$$

$$\mathbf{Q}(\mathbf{s}) = \mathbf{W}_3\mathbf{h}_2 + \mathbf{b}_3, \quad \mathbf{W}_3 \in \mathbb{R}^{4\times 64}. \tag{12}$$

Pour imposer le respect des contraintes physiques et réglementaires de circulation, un masque d'actions valides

Algorithm 1 Contrôle adaptatif par Double DQN sous contraintes

Require: Réseau principal $Q_{\boldsymbol{\theta}}$, réseau cible $Q_{\boldsymbol{\theta}^-}$, Replay Buffer $\mathcal{D}$.
Require: Paramètres : $\alpha = 5 \times 10^{-4}$, $\gamma = 0{,}99$, $\Delta t = 5\,\mathrm{s}$, $\tau = 0{,}005$.
Initialiser $\boldsymbol{\theta}^- \leftarrow \boldsymbol{\theta}$, $\mathcal{D} \leftarrow \emptyset$.
for chaque épisode $= 1$ **to** E **do**
  Réinitialiser SUMO avec la graine courante, observer $\mathbf{s}_0$.
  for $t = 0, \Delta t, 2\Delta t, \ldots, T$ **do**
    Calculer le masque d'actions autorisées $\mathcal{M}(\mathbf{s}_t)$.
    Avec probabilité ε, choisir $a_t \in \mathcal{M}(\mathbf{s}_t)$ uniformément ;
    Sinon, choisir $a_t = \arg\max_{a \in \mathcal{M}(\mathbf{s}_t)} Q(\mathbf{s}_t, a; \boldsymbol{\theta})$.
    if $a_t \neq a_{t-1}$ **then**
      Appliquer le jaune intermédiaire de $y = 3\,\mathrm{s}$ via TraCI.
    end if
    Maintenir la phase a_t durant Δt, avancer la simulation.
    Observer l'état $\mathbf{s}_{t+1}$ et calculer r_t selon (7).
    Enregistrer la transition $(\mathbf{s}_t, a_t, r_t, \mathbf{s}_{t+1})$ dans $\mathcal{D}$.
    Échantillonner un mini-lot de taille 64 dans $\mathcal{D}$.
    Calculer les cibles Y^{DoubleQ} selon (8).
    Mettre à jour $\boldsymbol{\theta}$ par gradient sur la perte (9).
    Mettre à jour le réseau cible : $\boldsymbol{\theta}^- \leftarrow \tau\boldsymbol{\theta} + (1-\tau)\boldsymbol{\theta}^-$.
  end for
end for

$\mathcal{M}(\mathbf{s}_t) \subset \mathcal{A}$ est appliqué avant le calcul de l'action :

$$\mathcal{M}(\mathbf{s}_t) = \begin{cases} \{a_{t-1}\} & \text{si } t_{\text{green}} < g_{\min}, \\ \mathcal{A} \setminus \{a_{t-1}\} & \text{si } t_{\text{green}} \geq g_{\max}, \\ \mathcal{A} & \text{sinon.} \end{cases} \tag{13}$$

Les valeurs Q associées aux actions non autorisées par le masque sont positionnées à $-\infty$, garantissant qu'aucune phase interdite ne puisse être choisie lors de la sélection ε-greedy. Durant la phase d'entraînement, le paramètre d'exploration ε décroît linéairement de $1{,}0$ à $0{,}05$ sur $30\,000$ pas de décision. Lors de l'évaluation finale, l'agent opère en mode purement déterministe ($\varepsilon = 0$). L'Algorithme 1 résume l'ensemble de la boucle d'apprentissage.

5. Protocole expérimental

5.1. Environnement de simulation

Les simulations sont exécutées sous la plateforme microscopique Eclipse SUMO (version 1.26.0), interfacée via la bibliothèque Python TraCI. La topologie modélisée reproduit la géométrie réelle du carrefour de Thiès extraite d'OpenStreetMap.

Le pas d'intégration physique de la simulation est configuré à $\Delta t_{\text{sim}} = 1{,}0\,\mathrm{s}$ (`-step-length 1.0`). Afin d'éviter tout chevauchement avec la logique interne des feux de SUMO, le contrôle est opéré de façon exclusive au moyen de la commande TraCI `setRedYellowGreenState()`. Les décisions de l'agent sont sollicitées à intervalles réguliers de $\Delta t = 5{,}0\,\mathrm{s}$.

5.2. Graines stochastiques et demande

L'évaluation statistique repose sur un protocole multi-graines rigoureux :

— La durée de chaque épisode d'évaluation est fixée à $T_{\text{eval}} = 3600\,\mathrm{s}$ (1 heure de trafic continu).
— L'évaluation est menée sur cinq graines pseudo-aléatoires indépendantes :

$$\mathcal{S}_{\text{eval}} = \{7, 13, 21, 42, 77\}. \tag{14}$$

Ces graines régissent les tirages des instants d'injection et des itinéraires des véhicules dans la configuration `rl.sumocfg`. Elles sont strictement disjointes des graines utilisées lors de la phase d'apprentissage de l'agent.

5.3. Contrôleurs de référence

L'agent Double DQN est comparé à trois régulateurs de référence exécutés sur les mêmes configurations de trafic :

1. **Plan fixe (programme SUMO d'origine) :** Programme cyclique pré-paramétré dans le réseau SUMO, d'une durée de cycle totale de $C = 78\,\mathrm{s}$, décomposé en Phase 0 ($27\,\mathrm{s}$), Jaune ($3\,\mathrm{s}$), Phase 1 ($6\,\mathrm{s}$), Jaune ($3\,\mathrm{s}$), Phase 2 ($27\,\mathrm{s}$), Jaune ($3\,\mathrm{s}$), Phase 3 ($6\,\mathrm{s}$), Jaune ($3\,\mathrm{s}$).
2. **Contrôleur actionné (*Actuated gap-out*) :** Régulateur à détection de trou de trafic prolongeant le vert tant que l'intervalle temporel entre passages successifs reste inférieur à $\Delta t_{\text{gap}} = 3{,}0\,\mathrm{s}$, sous contraintes $g_{\min} = 10\,\mathrm{s}$ et $g_{\max} = 60\,\mathrm{s}$.
3. **Max-Pressure Somme (*MP-Sum*) :** Règle heuristique de Varaiya sélectionnant la phase maximisant la somme des files des voies autorisées selon l'équation (2).
4. **Max-Pressure Maximum (*MP-Max*) :** Variante sélectionnant la phase dont la file d'approche maximale est la plus importante selon l'équation (3).

5.4. Métriques d'évaluation

Pour chaque simulation de $3600\,\mathrm{s}$, les grandeurs microscopiques individuelles des véhicules sont collectées dans le fichier `tripinfo.xml` :

— **timeLoss (s)** : Retard moyen subi par les véhicules par rapport à un trajet en écoulement libre théorique.
— **waitingTime (s)** : Temps moyen passé à l'arrêt complet ($v < 0{,}1\,\mathrm{m/s}$).
— **Durée (s)** : Temps moyen de parcours à travers le carrefour.

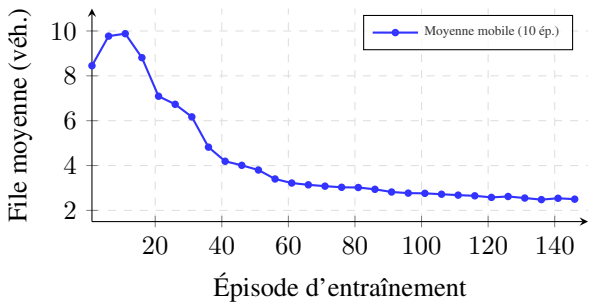


FIGURE 2 – Convergence de la file moyenne sur 150 épisodes d'entraînement (réduction de 9,88 à 2,50 véhicules).

— **Vitesse moyenne (m/s)** : Vitesse spatiale moyenne des véhicules ayant complété leur parcours.
— **Débit achevé** (n) : Nombre total de véhicules parvenus à destination au terme de l'heure simulée.
— **Véhicules non insérés** (N_{block}) : Nombre de véhicules générés par la demande mais restés bloqués en amont du réseau en raison de la saturation physique des voies d'entrée (*insertion spillback*).

6. Résultats expérimentaux

6.1. Performances consolidées sur 5 graines

Le tableau 1 présente les résultats agrégés sur les cinq graines d'évaluation.

L'agent Double DQN obtient une réduction de $50{,}7\,\%$ du temps perdu moyen par rapport au plan fixe ($15{,}5 \pm 0{,}6\,\text{s}$ contre $31{,}5 \pm 0{,}5\,\text{s}$), et abaisse le temps d'attente moyen à $9{,}0 \pm 0{,}5\,\text{s}$ (contre $23{,}8\,\text{s}$). La vitesse moyenne d'écoulement progresse de $6{,}37$ à $8{,}16\,\text{m/s}$, tandis que le débit de véhicules complétant leur trajet reste stable (≈ 889 véhicules, dans la plage observée de 840 à 890 véhicules pour ce réseau en écoulement complet).

Le régulateur actionné enregistre quant à lui un retard moyen de $34{,}2 \pm 1{,}1\,\text{s}$, soit une légère détérioration ($+8{,}7\,\%$) par rapport au plan fixe. Ce comportement découle du mécanisme de détection locale : en prolongeant le vert sur une approche en présence de véhicules isolés successifs, le contrôleur retarde le basculement vers les approches transversales, augmentant le retard moyen cumulé sur l'ensemble du carrefour.

L'algorithme Max-Pressure en mode Somme présente une dégradation marquée, avec un retard moyen de $71{,}7 \pm 15{,}2\,\text{s}$ et un débit achevé réduit à environ 580 véhicules, soit une baisse de débit d'environ $33\,\%$. La variante Max-Pressure Maximum, évaluée sur la graine 7, atténue ce retard à $45{,}7\,\text{s}$ avec un débit achevé de 798 véhicules, mais demeure moins performante que le plan statique de base.

6.2. Diagnostic microscopique de Max-Pressure sur la graine 7

Pour identifier précisément l'origine du dysfonctionnement de Max-Pressure en mode Somme, nous avons instrumenté la simulation de la graine 7 sur les $3600\,\text{s}$ en consignant le nombre de commutations de phases et la répartition temporelle exacte des temps de vert. Les mesures sont reportées dans le tableau 2.

Ces données permettent de trancher clairement entre les deux hypothèses explicatives possibles :

1. **Réfutation de l'hypothèse de *thrashing* :** L'algorithme MP-Sum n'effectue que 91 commutations de phase sur l'heure de simulation, soit nettement moins que le plan fixe (159) et que le Double DQN (210). La dégradation observée ne résulte donc pas d'une instabilité de commutation qui dissiperait le temps utile en phases jaunes d'inter-vert.
2. **Constat d'une famine de phase (*phase starvation*) :** L'algorithme alloue $80{,}8\,\%$ du temps vert total à la seule Phase 2 ($2910\,\text{s}$ sur $3600\,\text{s}$), $19{,}2\,\%$ à la Phase 0 ($690\,\text{s}$), et n'alloue **aucun temps de vert à la Phase 3** ($0{,}0\,\text{s}$).
3. **Mécanisme de refoulement amont (*spillback*) :** En l'absence de service sur la Phase 3, les véhicules affectés à ces mouvements de tourne-à-gauche restent bloqués sur leur voie. La file d'attente s'étend jusqu'à saturer physiquement l'approche d'entrée correspondante. Cet engorgement bloque l'insertion des véhicules générés par SUMO en périphérie du réseau, provoquant le blocage de 207 véhicules hors réseau. Ce phénomène de refoulement explique mécaniquement la baisse du nombre de véhicules ayant terminé leur trajet (≈ 580 au lieu de ≈ 889).

Le comportement de l'agent Double DQN contraste nettement avec celui de Max-Pressure Somme. Grâce à l'optimisation du retour cumulé actualisé ($\gamma = 0{,}99$), l'agent anticipe que laisser des véhicules immobiles indéfiniment sur une approche dégrade le temps d'attente cumulé futur $W(t + \Delta t)$ et, par voie de conséquence, les récompenses futures r_{t+k} définies par l'équation (7). L'agent alloue ainsi $41{,}5\,\%$ du vert à la Phase 0, $40{,}1\,\%$ à la Phase 2, et réserve $18{,}3\,\%$ du temps vert à la Phase 3. Cette purge périodique des files secondaires maintient le carrefour sous le seuil d'engorgement physique et assure un taux de blocage amont nul ($N_{\text{block}} = 0$).

7. Discussion

7.1. Apports et analyse comparative

Cette étude apporte un éclairage comportemental sur le contrôle adaptatif en environnement microscopique. Si Max-Pressure dispose de garanties théoriques solides en réseau continu, sa mise en œuvre sous forme d'une agrégation par somme brute de files d'attente se heurte, sur un carrefour asymétrique isolé, à un biais de représentativité : les axes à

TABLE 1 – Performances comparatives consolidées des contrôleurs sur 3600 s de simulation

Contrôleur	timeLoss (s) ↓	waitingTime (s) ↓	Durée (s) ↓	Vitesse (m/s) ↑	Débit (n) ↑	Écart / Fixe
Plan fixe (SUMO, 78 s)	$31{,}5 \pm 0{,}5$	$23{,}8 \pm 0{,}4$	$48{,}5 \pm 0{,}6$	$6{,}37 \pm 0{,}07$	≈ 872	Référence (0 %)
Actionné (*gap-out*)	$34{,}2 \pm 1{,}1$	$25{,}8 \pm 0{,}8$	$51{,}2 \pm 1{,}2$	$5{,}72 \pm 0{,}11$	≈ 874	+8,7 %
Max-Pressure (*MP-Sum*)†	$71{,}7 \pm 15{,}2$	$57{,}3 \pm 12{,}6$	$86{,}6 \pm 14{,}8$	$4{,}12 \pm 0{,}45$	≈ 580	+127,7 %
Max-Pressure (*MP-Max*)‡	45,7	37,7	63,2	6,65	≈ 798	+45,1 %
Double DQN	$\mathbf{15{,}5 \pm 0{,}6}$	$\mathbf{9{,}0 \pm 0{,}5}$	$\mathbf{32{,}7 \pm 0{,}7}$	$\mathbf{8{,}16 \pm 0{,}09}$	$\approx \mathbf{889}$	**−50,7 %**

Valeurs moyennes ± écart-type sur les 5 graines stochastiques ($\mathcal{S}_{\text{eval}} = \{7, 13, 21, 42, 77\}$), sauf mention explicite.

† Configuration présentant une famine de phase et un refoulement amont sur cette intersection.

‡ Mesuré sur la graine 7 uniquement (aucun écart-type inter-graines n'est rapporté).

TABLE 2 – Diagnostic microscopique d'allocation des phases sur la graine 7 (3600 s)

Contrôleur	Commut.	Phase 0	Phase 1	Phase 2	Phase 3	Non insérés
Plan fixe	159	40,9 %	9,1 %	40,9 %	9,1 %	0
Double DQN	210	41,5 %	0,0 %	40,1 %	**18,3 %**	**0**
MP-Sum	**91**	19,2 %	0,0 %	**80,8 %**	**0,0 %**	**207**

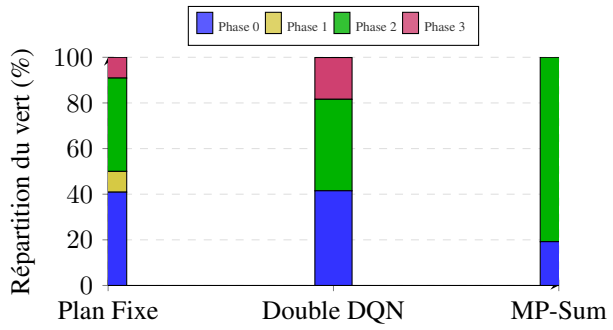


FIGURE 3 – Distribution temporelle relative des phases vertes (mesurée sur la graine 7 sur un horizon de 3600 s).

fort trafic ou à voies multiples présentent structurellement des sommes de files plus importantes que les mouvements de tourne-à-gauche secondaires, condamnant ces derniers à une famine prolongée dès lors que la demande reste soutenue.

La politique apprise par Double DQN résout ce problème d'arbitrage sans nécessiter de pondération manuelle des mouvements. En optimisant directement la résorption du temps d'attente cumulé global (ΔW), le modèle intègre implicitement la nécessité de purger les files secondaires avant qu'elles ne saturent l'espace de stockage amont.

7.2. Limites méthodologiques

Plusieurs limites du présent travail doivent être explicitées avec rigueur :

— **Intersection isolée et demande simulée :** Les évaluations sont réalisées sur un seul carrefour et une distribution de flux stochastique modélisée sous SUMO. Les interactions d'ondes de vert entre carrefours adjacents ne sont pas modélisées ici.

— **Calibrage du plan fixe de référence :** Le plan fixe évalué correspond au programme pré-existant dans le réseau SUMO ($C = 78$ s). Il n'a pas été recalculé analytiquement par la formule de Webster pour la matrice d'injection exacte de ces essais.

— **Couverture de la variante Max-Pressure Maximum :** L'évaluation de la variante MP-Max a été menée principalement sur la graine 7. Une campagne multi-graines complète sur cette variante sera nécessaire pour consolider la portée statistique de sa comparaison.

— **Absence de validation sur site réel :** L'état d'observation suppose une perception parfaite des longueurs de files et densités d'approches fournie par TraCI, sans bruit de détection ni occultation visuelle.

7.3. Perspectives

Les extensions naturelles de ces travaux porteront d'une part sur le passage à une coordination multi-agents (de type CoLight ou MAPPO) sur un corridor de plusieurs carrefours consécutifs, et d'autre part sur l'évaluation de la robustesse de l'agent face à des erreurs d'estimation des files d'attente, préfigurant l'intégration de capteurs visuels réels.

8. Conclusion

Dans cet article, nous avons évalué un contrôleur de feux adaptatif fondé sur l'algorithme Double DQN sur la modélisation du carrefour principal de Thiès (Sénégal) sous Eclipse SUMO. Confronté à un plan fixe à cycle de 78 s, à un contrôleur actionné et à l'algorithme Max-Pressure sur cinq graines stochastiques d'une heure, l'agent Double DQN réduit le temps perdu moyen de 50,7 % (15,5±0,6 s contre 31,5±0,5 s) tout en maintenant le débit d'évacuation maximal du réseau.

L'analyse microscopique de l'algorithme Max-Pressure a mis en lumière un phénomène de famine de phase sur la variante Somme, excluant toute hypothèse d'oscillation excessive (*thrashing*) et démontrant que la chute de débit découle d'un refoulement amont provoqué par la non-desserte d'une phase secondaire. L'agent Double DQN démontre sa capacité à éviter cette pathologie en insérant des purges courtes mais régulières sur les voies secondaires, illustrant l'intérêt d'un

critère fondé sur la variation d'attente cumulée pour l'exploitation de carrefours isolés asymétriques.

Références

[1] A. Haydari et Y. Yılmaz, « Deep reinforcement learning for intelligent transportation systems : A survey », *IEEE Transactions on Intelligent Transportation Systems*, vol. 23, n° 1, p. 11–30, 2022.

[2] F. V. Webster, « Traffic signal settings », *Road Research Technical Paper*, n° 39, Road Research Laboratory, HMSO, Londres, 1958.

[3] P. R. Lowrie, « SCATS, Sydney Co-ordinated Adaptive Traffic System : A traffic responsive method of controlling urban traffic », *Roads and Traffic Authority of New South Wales*, 1990.

[4] P. B. Hunt, D. I. Robertson, R. D. Bretherton et R. I. Winton, « SCOOT : a traffic responsive method of coordinating traffic signals », *TRRL Laboratory Report*, n° 1014, Transport and Road Research Laboratory, Crowthorne, 1981.

[5] H. Wei, G. Zheng, H. Yao et Z. Li, « IntelliLight : A reinforcement learning approach for intelligent traffic light control », dans *Proc. 24th ACM SIGKDD Int. Conf. Knowledge Discovery & Data Mining (KDD)*, 2018, p. 2496–2505.

[6] H. Wei, C. Chen, G. Zheng, K. Wu, V. Gayah, K. Xu et Z. Li, « PressLight : Decentralized reinforcement learning via localized reward for traffic signal control », dans *Proc. 25th ACM SIGKDD Int. Conf. Knowledge Discovery & Data Mining (KDD)*, 2019, p. 1916–1925.

[7] C. Chen, H. Wei, N. Xu, G. Zheng, M. Yang, Y. Xiong, K. Xu et Z. Li, « Toward a thousand lights : Decentralized deep reinforcement learning for large-scale traffic signal control », dans *Proc. 34th AAAI Conf. Artificial Intelligence (AAAI)*, vol. 34, n° 01, 2020, p. 3414–3421.

[8] C. Zhang, X. He et G. Wang, « PDLight : A deep reinforcement learning traffic light control algorithm with pressure and dynamic light duration », *arXiv preprint arXiv :2009.13711*, 2020.

[9] H. Wei, G. Zheng, V. Gayah et Z. Li, « Recent advances in reinforcement learning for traffic signal control : A survey of models and evaluation », *ACM SIGKDD Explorations Newsletter*, vol. 23, n° 2, p. 12–25, 2021.

[10] K. Zhao, X. Zhai et D. Guan, « Deep reinforcement learning for traffic signal control : A comprehensive review of algorithms, environments, and benchmark metrics », *IEEE Transactions on Intelligent Vehicles*, vol. 9, n° 3, p. 4110–4128, 2024.

[11] C. M. Day, H. Li, L. Richardson, J. Howard, T. Platte, J. R. Sturdevant et D. M. Bullock, « Detector-free optimization of traffic signal offsets with connected vehicle data », *Transportation Research Record*, vol. 2620, n° 1, p. 52–60, 2017.

[12] P. Varaiya, « Max pressure control of a network of signalized intersections », *Transportation Research Part C : Emerging Technologies*, vol. 36, p. 177–195, 2013.

[13] J. Lioris, R. Pedarsani, F. Y. Tascikaraoglu et P. Varaiya, « Platooning for coupled car-following and maximum throughput at signalized intersections », *Transportation Research Part C : Emerging Technologies*, vol. 71, p. 295–312, 2016.

[14] V. Mnih *et al.*, « Human-level control through deep reinforcement learning », *Nature*, vol. 518, n° 7540, p. 529–533, 2015.

[15] W. Genders et S. Razavi, « Using deep reinforcement learning for traffic light control », *Transportation Research Record*, vol. 2620, n° 1, p. 52–60, 2016.

[16] H. van Hasselt, A. Guez et D. Silver, « Deep reinforcement learning with double Q-learning », dans *Proc. 30th AAAI Conf. Artificial Intelligence (AAAI)*, 2016, p. 2094–2100.