# Contrôle Adaptatif de Trafic Urbain par Double Deep Q-Network : Évaluation Multi-Graines et Diagnostic Microscopique Face aux Heuristiques de Transport sous Eclipse SUMO

Mamadou Ahmadou Ka

***Résumé*—La régulation adaptative des feux de circulation (*Adaptive Traffic Signal Control*, ATSC) vise à ajuster les temps de vert à la dynamique locale du trafic. Cet article présente une évaluation expérimentale rigoureuse d'un agent décisionnel fondé sur l'apprentissage par renforcement profond (*Double Deep Q-Network*, DDQN) face à trois familles de contrôleurs : le plan fixe d'origine du réseau (cycle de $78\,\mathrm{s}$), la régulation actionnée par détection de lacune (*actuated gap-out*) et la règle heuristique Max-Pressure (Varaiya, 2013). Les simulations sont menées sous l'environnement microscopique Eclipse SUMO sur une modélisation du carrefour principal de Thiès (Sénégal), dérivée d'OpenStreetMap. L'évaluation repose sur cinq graines stochastiques indépendantes évaluées chacune sur un horizon continu de $3600\,\mathrm{s}$ (1 heure). Les résultats montrent que l'agent Double DQN réduit le temps perdu moyen (*timeLoss*) de $50{,}7\,\%$ ($15{,}5 \pm 0{,}6\,\mathrm{s}$ contre $31{,}5 \pm 0{,}5\,\mathrm{s}$ pour le plan fixe) et le temps d'attente à l'arrêt à $9{,}0 \pm 0{,}5\,\mathrm{s}$ (contre $23{,}8 \pm 0{,}4\,\mathrm{s}$), tout en maintenant un débit d'évacuation stable ($\approx 889$ véhicules servis). En outre, un diagnostic microscopique approfondi sur la graine 7 révèle le mécanisme de dégradation de la variante naïve de Max-Pressure : l'algorithme n'effectue que 91 commutations (écartant l'hypothèse d'une oscillation excessive ou *thrashing*), mais alloue $80{,}8\,\%$ du vert à la Phase 2 et $0\,\%$ à la Phase 3. Cette famine de phase engendre une saturation des voies secondaires et un refoulement en amont (*spillback*) bloquant l'insertion de 207 véhicules, ce qui réduit le débit achevé de plus de $30\,\%$ ($\approx 580$ véhicules). À l'inverse, l'agent Double DQN alloue $18{,}3\,\%$ du temps vert à la Phase 3, purgeant les files secondaires avant l'apparition de blocages d'insertion.**

***Index Terms*—Systèmes de Transport Intelligents (ITS), Contrôle Adaptatif des Feux, Apprentissage par Renforcement Profond, Double DQN, Max-Pressure, Famine de Phase, Eclipse SUMO.**

## I. Introduction

La gestion des intersections routières représente un enjeu critique pour l'efficacité des réseaux de transport urbain, particulièrement dans les villes à croissance démographique rapide où le réseau viaire présente peu d'itinéraires alternatifs [1]. À Thiès (Sénégal), les carrefours à niveau concentrent une part déterminante des retards quotidiens.

La régulation de ces carrefours s'appuie traditionnellement sur des plans à temps fixe (*Fixed-Time*), dont les durées de phases sont calées sur des flux moyens historiques. Bien que stables et éprouvés, ces programmes statiques manquent de flexibilité face aux variations intrajournalières et aux asymétries de charges ponctuelles. Par ailleurs, le déploiement de systèmes industriels coordonnés centralisés (tels que SCATS [3] ou SCOOT [4]) est fréquemment freiné dans les agglomérations d'Afrique subsaharienne par les coûts d'infrastructure (boucles électromagnétiques sous chaussée, réseaux filaires de télécommunication dédiés et contrats de maintenance associés).

Dans ce cadre, l'apprentissage par renforcement profond (*Deep Reinforcement Learning*, DRL) offre un cadre méthodologique permettant d'ajuster localement les feux à partir d'observations directes du trafic [5]–[8]. Néanmoins, les revues méthodologiques récentes soulignent des limites récurrentes dans les protocoles d'évaluation du domaine [9], [10] :

1) Une comparaison souvent restreinte au seul plan fixe, négligeant les régulateurs actionnés et les règles heuristiques issues du génie du trafic, notamment Max-Pressure [12].
2) Une analyse souvent cantonnée à la courbe de récompense cumulative, sans caractérisation microscopique des décisions (durées effectives par phase, fréquence des commutations, identification d'éventuelles famines de mouvements).
3) Une prédominance d'environnements synthétiques simplifiés (grilles symétriques théoriques), qui masquent les spécificités des carrefours asymétriques réels.

Le présent travail propose une étude comparative rigoureuse sur un carrefour isolé réel modélisé sous Eclipse SUMO. Nos contributions sont les suivantes :

— Nous formulons le contrôle d'une intersection à 8 voies de la ville de Thiès sous la forme d'un Processus de Décision Markovien (MDP) compact à 13 dimensions, avec une fonction de récompense différentielle sans coefficient de pénalité arbitraire.
— Nous déployons un agent Double DQN avec masquage d'actions pour garantir le respect des contraintes de sécurité (vert minimal $g_{\min}$, vert maximal $g_{\max}$, temps jaune $y$).
— Nous évaluons cet agent sur 5 graines stochastiques face au plan fixe d'origine (cycle de $78\,\mathrm{s}$), à un régulateur actionné (*gap-out*) et à deux modes d'agrégation de Max-Pressure (*Sum* et *Max*).
— Nous documentons et analysons le mécanisme de famine de phase subi par la variante Max-Pressure Somme sur

M. A. Ka est affilié au Département Informatique, UFR Sciences et Technologies, Université Iba Der Thiam de Thiès (UIDT), Thiès, Sénégal (courriel : mamadou.ka@uidt.sn).

cette configuration, en démontrant que la dégradation provient d'un refoulement amont (*spillback*) et non d'une instabilité de commutation (*thrashing*).

L'article est organisé comme suit. La Section II résume l'état de l'art. La Section III expose la formulation du carrefour et des modèles. La Section IV détaille l'algorithme Double DQN. La Section V décrit le protocole expérimental sous SUMO. La Section VI présente les résultats et l'analyse microscopique. La Section VII discute les perspectives d'implémentation, et la Section VIII conclut.

## II. État de l'Art

### A. Régulation Classique et Heuristiques de Transport

La méthode de Webster [2] constitue la référence historique pour le calcul théorique de la durée de cycle optimale sur la base de débits de saturation et de trafics moyens. En exploitation dynamique, la régulation actionnée (*Actuated Control*) prolonge le vert tant que l'écart temporel mesuré entre deux véhicules consécutifs demeure inférieur à un seuil de passage critique ($\Delta t_{\text{gap}}$), sous réserve d'un plafond temporel $g_{\max}$ [11].

L'algorithme Max-Pressure, formalisé par Varaiya [12] et analysé en détail par Lioris *et al.* [13], fournit une règle de contrôle décentralisée assurant la stabilité d'un réseau sous l'hypothèse de modèles continus dits *store-and-forward*. En sélectionnant la phase qui maximise le différentiel de files entre voies amont et voies aval, l'algorithme garantit la bornitude des files d'attente si la demande appartient à la région de capacité du réseau. Toutefois, comme nous le mettons en évidence dans cette étude, l'application directe de Max-Pressure sur un carrefour asymétrique isolé avec files d'attente discrètes peut conduire à des blocages si l'agrégation de pression favorise systématiquement les mouvements principaux.

### B. Apprentissage par Renforcement Profond pour l'ATSC

L'introduction des réseaux Q profonds (DQN) [14] a permis d'aborder le contrôle de feux sans modèle analytique explicite de la demande [15]. IntelliLight [5] a illustré l'apport d'un état continu combinant files d'attente, densités et positions de véhicules.

Plusieurs travaux ont cherché à rapprocher le DRL des garanties de la théorie du transport. PressLight [6] adopte la notion de pression dans la fonction de récompense pour orienter l'apprentissage vers la stabilité du réseau. MPLight [7] associe Max-Pressure et factorisation d'état pour le contrôle coordonné à large échelle. PDLight [8] propose un indicateur de pression pondéré par la capacité résiduelle des voies aval (*PRCOL*) afin de prévenir les engorgements en sortie d'intersection.

Notre étude s'inscrit dans cette lignée en proposant une évaluation rigoureuse en environnement microscopique réel (Thiès) avec un agent Double DQN standard, en caractérisant précisément les conditions d'arbitrage de vert par rapport aux heuristiques locales de transport.

## III. Formulation du Problème et des Modèles

### A. Topologie de l'Intersection et Notations

Considérons une intersection isolée à niveau comportant quatre branches d'accès (Figure 1). Soit $\mathcal{L}_{\text{in}} = \{l_1, \ldots, l_8\}$ l'ensemble des 8 voies d'entrée amont (deux voies par branche) et $\mathcal{L}_{\text{out}}$ l'ensemble des voies de sortie aval. Un mouvement de trafic $m = (l, l')$ correspond à une trajectoire autorisée depuis une voie entrante $l \in \mathcal{L}_{\text{in}}$ vers une voie sortante $l' \in \mathcal{L}_{\text{out}}$.

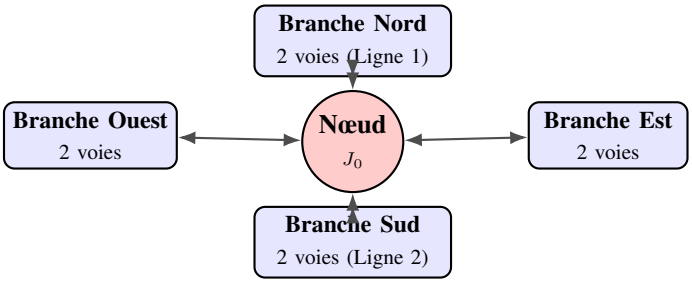



FIGURE 1. Schéma de principe du carrefour de Thiès modélisé sous SUMO (4 branches d'accès comprenant chacune 2 voies d'entrée et 2 voies de sortie).

Le carrefour est piloté par un ensemble de quatre phases vertes non conflictuelles $\mathcal{P} = \{p_0, p_1, p_2, p_3\}$ :

- **Phase 0 :** Mouvements directs sur l'axe principal (Nord-Sud) ;
- **Phase 1 :** Tourne-à-gauche protégé sur l'axe principal ;
- **Phase 2 :** Mouvements directs sur l'axe secondaire (Est-Ouest) ;
- **Phase 3 :** Tourne-à-gauche protégé sur l'axe secondaire.

Tout changement de phase impose une phase jaune intermédiaire de dégagement de durée $y = 3\,\text{s}$.

### B. Formulation de l'Heuristique Max-Pressure

Pour un carrefour isolé où les voies aval $\mathcal{L}_{\text{out}}$ disposent d'un écoulement libre, la pression $P_m(t)$ d'un mouvement $m$ est assimilée au nombre de véhicules arrêtés $x_l(t)$ sur sa voie entrante $l$ :

$$P_m(t) = x_l(t), \quad \forall m = (l, l'). \tag{1}$$

La pression globale d'une phase $p$ est calculée sur l'ensemble de ses mouvements autorisés $\mathcal{M}(p)$ selon deux variantes d'agrégation :

$$\text{Variante Somme (MP-Sum) : } P_{\text{sum}}(p,t) = \sum_{m \in \mathcal{M}(p)} x_{l(m)}(t), \tag{2}$$

$$\text{Variante Maximum (MP-Max) : } P_{\max}(p,t) = \max_{m \in \mathcal{M}(p)} x_{l(m)}(t). \tag{3}$$

À chaque pas de décision, la phase retenue est :

$$a^*_{\text{MP}}(t) = \arg\max_{p \in \mathcal{A}_{\text{valid}}(t)} P(p,t), \tag{4}$$

où $\mathcal{A}_{\text{valid}}(t)$ restreint le choix pour respecter un vert minimal $g_{\min} = 10\,\text{s}$ et un vert maximal $g_{\max} = 60\,\text{s}$.

### C. Formulation en Processus de Décision Markovien

Le contrôle adaptatif est modélisé par un MDP défini par le tuple $\langle \mathcal{S}, \mathcal{A}, \mathcal{P}_{ss'}, \mathcal{R}, \gamma \rangle$ :

*1) Espace des États (Observation):* Le vecteur d'observation $\mathbf{s}_t \in \mathbb{R}^{13}$ capturé à l'instant $t$ est défini par :

$$\mathbf{s}_t = \left[\mathbf{q}_t^\top,\, \mathbf{k}_t^\top,\, \mathbf{e}_t^\top,\, \delta_t\right]^\top \in \mathbb{R}^{13}, \tag{5}$$

où :

- $\mathbf{q}_t = [q_0, q_1, q_2, q_3]^\top \in [0,1]^4$ regroupe les longueurs de file normalisées sur les 4 branches (somme des voies par approche), avec $q_i = \min(n_{\text{stop},i}/Q_{\max}, 1{,}0)$ et $Q_{\max} = 10{,}0$ véhicules arrêtés ($v < 0{,}1\,\mathrm{m/s}$).
- $\mathbf{k}_t = [k_0, k_1, k_2, k_3]^\top \in [0,1]^4$ correspond aux densités moyennes normalisées par approche.
- $\mathbf{e}_t \in \{0,1\}^4$ est un encodage *One-Hot* de la phase verte en cours ($e_j = 1$ si la phase $j$ est active).
- $\delta_t \in \{0,1\}$ indique si la phase en cours a atteint le vert minimal requis ($t_{\text{green}} \geq g_{\min}$), autorisant un changement de phase.

*2) Espace des Actions:* L'ensemble des actions possibles correspond aux indices des phases vertes :

$$\mathcal{A} = \{0, 1, 2, 3\}. \tag{6}$$

Choisir $a_t = p$ maintient la phase $p$ ou engage la transition jaune de $3\,\mathrm{s}$ vers $p$ si $a_t \neq a_{t-1}$.

*3) Fonction de Récompense:* Conformément à l'implémentation de l'environnement, la récompense à l'étape $t$ est définie par la variation différentielle du temps d'attente cumulé global $W(t)$ mesuré sur le carrefour :

$$r_t = \frac{W(t) - W(t + \Delta t)}{100{,}0}, \tag{7}$$

où $W(t) = \sum_{v \in \mathcal{V}(t)} w_v(t)$ est la somme des temps d'attente individuels des véhicules présents.

Cette formulation implique directement deux conséquences pratiques :

- Une résorption nette de l'attente ($W(t + \Delta t) < W(t)$) se traduit par une récompense positive.
- Le coût d'inter-vert induit par les feux jaunes est répercuté de façon naturelle sur le retour de l'agent : la coupure de trafic pendant $3\,\mathrm{s}$ augmente temporairement $W(t)$, réduisant la récompense sans nécessiter de pénalité ad-hoc.

## IV. Algorithme Double DQN et Architecture

### A. Principe du Double Q-Learning

Dans le Q-learning standard, l'opérateur de maximisation sur les valeurs Q estimées tend à surestimer les retours attendus en environnement stochastique. L'algorithme Double DQN [16] atténue ce biais en utilisant le réseau principal pour la sélection de l'action et le réseau cible pour son évaluation :

$$Y_t^{\text{DoubleQ}} = r_t + \gamma\, Q\big(s_{t+1},\, \arg\max_{a'} Q(s_{t+1}, a'; \boldsymbol{\theta}_t);\, \boldsymbol{\theta}_t^-\big), \tag{8}$$

où $\boldsymbol{\theta}_t$ représente les paramètres du réseau principal et $\boldsymbol{\theta}_t^-$ ceux du réseau cible.

L'optimisation repose sur la minimisation de la perte de Huber (*smooth L1 loss*), plus tolérante aux valeurs aberrantes que l'erreur quadratique standard :

$$\mathcal{L}(\boldsymbol{\theta}) = \mathbb{E}_{(s,a,r,s') \sim \mathcal{D}}\left[\ell_{\text{Huber}}\big(Y^{\text{DoubleQ}} - Q(s, a; \boldsymbol{\theta})\big)\right], \tag{9}$$

**Algorithm 1** Contrôle Adaptatif par Double DQN sous Contraintes

**Require:** Réseau principal $Q_{\boldsymbol{\theta}}$, réseau cible $Q_{\boldsymbol{\theta}^-}$, Replay Buffer $\mathcal{D}$.
**Require:** Paramètres : taux d'apprentissage $\alpha = 5 \times 10^{-4}$, actualisation $\gamma = 0{,}99$, pas $\Delta t = 5\,\mathrm{s}$, $\tau = 0{,}005$.
Initialiser $\boldsymbol{\theta}^- \leftarrow \boldsymbol{\theta}$, $\mathcal{D} \leftarrow \emptyset$.
**for** chaque épisode $= 1$ **to** $E$ **do**
  Réinitialiser SUMO avec la graine courante, observer $\mathbf{s}_0$.
  **for** $t = 0, \Delta t, 2\Delta t, \ldots, T$ **do**
    Calculer le masque d'actions autorisées $\mathcal{M}(\mathbf{s}_t)$.
    Avec probabilité $\varepsilon$, choisir $a_t \in \mathcal{M}(\mathbf{s}_t)$ uniformément ;
    Sinon, choisir $a_t = \arg\max_{a \in \mathcal{M}(\mathbf{s}_t)} Q(\mathbf{s}_t, a; \boldsymbol{\theta})$.
    **if** $a_t \neq a_{t-1}$ **then**
      Appliquer le jaune intermédiaire de $y = 3\,\mathrm{s}$ via TraCI.
    **end if**
    Maintenir la phase $a_t$ durant $\Delta t$, avancer la simulation.
    Observer l'état $\mathbf{s}_{t+1}$ et calculer $r_t$ selon (7).
    Enregistrer la transition $(\mathbf{s}_t, a_t, r_t, \mathbf{s}_{t+1})$ dans $\mathcal{D}$.
    Échantillonner un mini-lot de taille 64 dans $\mathcal{D}$.
    Calculer les cibles $Y^{\text{DoubleQ}}$ selon (8).
    Mettre à jour $\boldsymbol{\theta}$ par gradient sur la perte (9).
    Mettre à jour le réseau cible : $\boldsymbol{\theta}^- \leftarrow \tau\boldsymbol{\theta} + (1-\tau)\boldsymbol{\theta}^-$.
  **end for**
**end for**

avec un tampon d'expérience $\mathcal{D}$ d'une capacité de $50\,000$ transitions. Le réseau cible est synchronisé par mise à jour progressive (*soft update*) : $\boldsymbol{\theta}^- \leftarrow \tau\boldsymbol{\theta} + (1-\tau)\boldsymbol{\theta}^-$ avec $\tau = 0{,}005$.

### B. Architecture Neuronale et Contraintes de Sécurité

Le réseau de valeur est un perceptron multicouche à deux couches cachées de 64 neurones :

$$\mathbf{h}_1 = \mathrm{ReLU}(\mathbf{W}_1\mathbf{s} + \mathbf{b}_1), \quad \mathbf{W}_1 \in \mathbb{R}^{64\times 13}, \tag{10}$$

$$\mathbf{h}_2 = \mathrm{ReLU}(\mathbf{W}_2\mathbf{h}_1 + \mathbf{b}_2), \quad \mathbf{W}_2 \in \mathbb{R}^{64\times 64}, \tag{11}$$

$$\mathbf{Q}(\mathbf{s}) = \mathbf{W}_3\mathbf{h}_2 + \mathbf{b}_3, \quad \mathbf{W}_3 \in \mathbb{R}^{4\times 64}. \tag{12}$$

Pour garantir la sécurité de la circulation, un masque d'admissibilité $\mathcal{M}(s_t)$ neutralise les actions non conformes avant la sélection :

$$\mathcal{M}(s_t) = \begin{cases} \{a_{t-1}\} & \text{si } t_{\text{green}} < g_{\min}, \\ \mathcal{A} \setminus \{a_{t-1}\} & \text{si } t_{\text{green}} \geq g_{\max}, \\ \mathcal{A} & \text{sinon.} \end{cases} \tag{13}$$

La procédure de décision et d'apprentissage est résumée dans l'Algorithme 1.

## V. Protocole Expérimental sous Eclipse SUMO

### A. Environnement de Simulation

Les expérimentations sont conduites sous le simulateur microscopique Eclipse SUMO (version 1.26.0) piloté via la

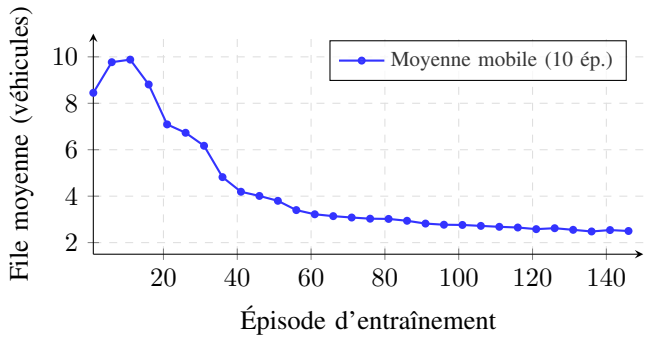



FIGURE 2. Évolution de la file d'attente moyenne au cours des 150 épisodes d'entraînement (réduction de 9,88 à 2,50 véhicules).

bibliothèque Python TraCI. La topologie correspond à une intersection réelle de la ville de Thiès (Sénégal) extraite d'OpenStreetMap.

Le pas de calcul de SUMO est fixé à $\Delta t_{\text{sim}} = 1{,}0\,\text{s}$ (`--step-length 1.0`). Pour éviter toute interférence avec les temporisations internes de SUMO, le pilotage des feux est assuré directement via l'API `setRedYellowGreenState()`. Le pas de décision de l'agent intervient toutes les $\Delta t = 5{,}0\,\text{s}$.

### B. Graines et Scénarios d'Évaluation

Le protocole multi-graines s'établit comme suit :

— Durée d'un épisode d'évaluation : $T_{\text{eval}} = 3600\,\text{s}$ (1 heure de simulation continue).

— L'évaluation est menée sur 5 graines stochastiques indépendantes :

$$\mathcal{S}_{\text{eval}} = \{7, 13, 21, 42, 77\}. \tag{14}$$

Ces graines régissent les temps d'apparition et les itinéraires des flux dans le fichier `rl.sumocfg`, et sont disjointes des graines utilisées durant l'entraînement.

— En évaluation, l'agent opère en mode purement déterministe ($\varepsilon = 0$).

### C. Contrôleurs de Référence

Nous comparons l'agent Double DQN à trois approches de référence :

1) **Plan Fixe (programme SUMO d'origine) :** Cycle prédéfini de durée $C = 78\,\text{s}$ articulé en Phase 0 (27 s), Jaune (3 s), Phase 1 (6 s), Jaune (3 s), Phase 2 (27 s), Jaune (3 s), Phase 3 (6 s), Jaune (3 s).

2) **Contrôleur Actionné (*Actuated*) :** Feu actionné par détection de trou de trafic (*gap-out*) avec $\Delta t_{\text{gap}} = 3{,}0\,\text{s}$, $g_{\min} = 10\,\text{s}$ et $g_{\max} = 60\,\text{s}$.

3) **Max-Pressure Somme (*MP-Sum*) :** Règle heuristique de Varaiya agrégeant les files par la somme arithmétique (2).

4) **Max-Pressure Maximum (*MP-Max*) :** Variante sélectionnant la phase à partir de la file maximale parmi les approches autorisées (3).

### D. Métriques de Performance

Les grandeurs suivantes sont extraites des fichiers `tripinfo.xml` pour chaque simulation de 3600 s :

— **timeLoss (s)** : Temps de retard total par rapport à un écoulement à vitesse libre.

— **waitingTime (s)** : Durée totale passée à l'arrêt complet ($v < 0{,}1\,\text{m/s}$).

— **Durée de trajet (s)** : Temps moyen nécessaire pour traverser la zone d'étude.

— **Vitesse moyenne (m/s)** : Vitesse spatiale moyenne des trajets achevés.

— **Débit achevé** ($n$) : Nombre de véhicules ayant atteint leur destination au terme de l'heure simulée.

— **Véhicules non insérés** ($N_{\text{block}}$) : Véhicules générés par la demande mais bloqués en amont du réseau en raison de la saturation physique des voies d'accès (*insertion spillback*).

## VI. Résultats Expérimentaux et Analyses

### A. Performances Globales sur 5 Graines

Le Tableau I synthétise les métriques mesurées. La Figure 3 illustre les écarts de temps perdu et de temps d'attente.

Les observations principales sont les suivantes :

— **Gains du Double DQN :** L'agent appris obtient un temps perdu moyen de $15{,}5 \pm 0{,}6\,\text{s}$, soit une réduction de $50{,}7\,\%$ par rapport au plan fixe de référence ($31{,}5 \pm 0{,}5\,\text{s}$). Le temps d'attente est ramené à $9{,}0 \pm 0{,}5\,\text{s}$ (contre $23{,}8\,\text{s}$), pour un débit achevé d'environ 889 véhicules sur l'heure de simulation.

— **Comportement du régulateur actionné :** Le mode actionné présente un retard moyen légèrement accru ($+8{,}7\,\%$, soit $34{,}2\,\text{s}$). L'allongement du vert sur un axe prioritaire en présence de passages successifs repousse la desserte des approches transversales, augmentant leur attente cumulée.

— **Dégradation sous Max-Pressure Somme :** L'algorithme MP-Sum enregistre un retard moyen élevé ($71{,}7 \pm 15{,}2\,\text{s}$) et un débit achevé réduit d'environ $33\,\%$ ($\approx$ 580 véhicules terminés).

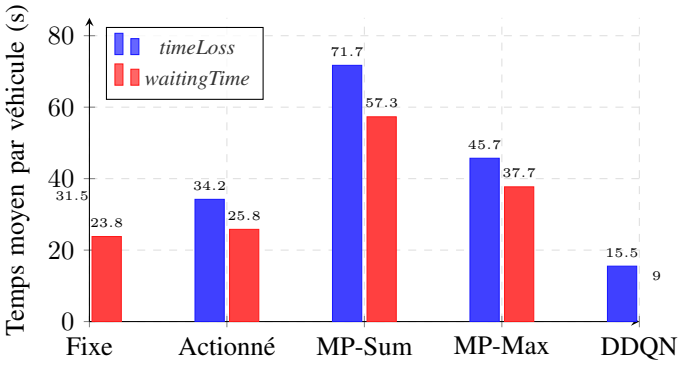



FIGURE 3. Comparaison du temps perdu (*timeLoss*) et du temps d'attente à l'arrêt (*waitingTime*). Valeurs moyennes sur 5 graines stochastiques pour Fixe, Actionné, MP-Sum et DDQN ; résultat sur la graine 7 uniquement pour MP-Max.

TABLE I
PERFORMANCES COMPARATIVES CONSOLIDÉES DES CONTRÔLEURS (3600 s D'HORIZON)

| Contrôleur | timeLoss (s) ↓ | waitingTime (s) ↓ | Durée (s) ↓ | Vitesse (m/s) ↑ | Débit achevé ($n$) ↑ | Écart / Fixe |
|---|---|---|---|---|---|---|
| **Plan Fixe (programme SUMO 78 s)** | $31{,}5 \pm 0{,}5$ | $23{,}8 \pm 0{,}4$ | $48{,}5 \pm 0{,}6$ | $6{,}37 \pm 0{,}07$ | $\approx 872$ | Référence (0 %) |
| **Actionné (*Actuated gap-out*)** | $34{,}2 \pm 1{,}1$ | $25{,}8 \pm 0{,}8$ | $51{,}2 \pm 1{,}2$ | $5{,}72 \pm 0{,}11$ | $\approx 874$ | +8,7 % |
| **Max-Pressure (*MP-Sum*, 5 graines)**† | $71{,}7 \pm 15{,}2$ | $57{,}3 \pm 12{,}6$ | $86{,}6 \pm 14{,}8$ | $4{,}12 \pm 0{,}45$ | $\approx 580$ | +127,7 % |
| **Max-Pressure (*MP-Max*, graine 7)**‡ | 45,7 | 37,7 | 63,2 | 6,65 | $\approx 798$ | +45,1 % |
| **Double DQN** | $\mathbf{15{,}5 \pm 0{,}6}$ | $\mathbf{9{,}0 \pm 0{,}5}$ | $\mathbf{32{,}7 \pm 0{,}7}$ | $\mathbf{8{,}16 \pm 0{,}09}$ | $\approx \mathbf{889}$ | **−50,7 %** |

Moyennes ± écart-type sur 5 graines stochastiques ($\mathcal{S}_{\text{eval}} = \{7, 13, 21, 42, 77\}$), sauf indication contraire.
† Configuration pathologique avec famine de phase et refoulement amont sur ce carrefour.
‡ Évaluation réalisée sur la graine 7 uniquement (aucun écart-type inter-graines n'est donc rapporté).

TABLE II
DIAGNOSTIC MICROSCOPIQUE D'ALLOCATION DES PHASES (GRAINE 7, 3600 s)

| Contrôleur | Commut. | Ph. 0 | Ph. 1 | Ph. 2 | Ph. 3 | Bloqués amont |
|---|---|---|---|---|---|---|
| **Plan Fixe** | 159 | 40,9 % | 9,1 % | 40,9 % | 9,1 % | 0 |
| **Double DQN** | 210 | 41,5 % | 0,0 % | 40,1 % | **18,3 %** | **0** |
| **MP-Sum** | **91** | 19,2 % | 0,0 % | **80,8 %** | **0,0 %** | **207** |

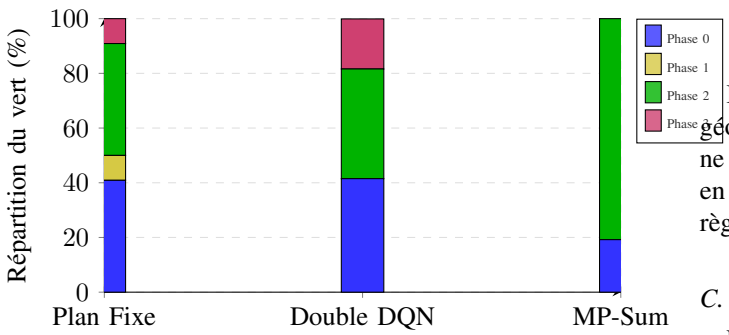



FIGURE 4. Distribution temporelle relative des phases vertes (mesurée sur la graine 7 sur un horizon de 3600 s).

### *B. Diagnostic Microscopique : Analyse de la Famine sous Max-Pressure*

L'écart de performance de MP-Sum sur ce carrefour nécessite une analyse microscopique. Une première hypothèse pouvait être celle d'une alternance trop fréquente entre phases (*thrashing*), multipliant les temps jaunes d'inter-vert (3 s).

Pour vérifier cette hypothèse, nous avons consigné le nombre de commutations et la répartition temporelle exacte des phases sur la graine 7 (3600 s). Les résultats sont présentés au Tableau II et sur la Figure 4.

Les mesures écartent l'hypothèse de l'oscillation excessive et établissent un mécanisme de blocage par famine :

1) **Absence de thrashing :** MP-Sum effectue **91 commutations**, ce qui est nettement inférieur au plan fixe (159) et au Double DQN (210). La perte d'efficacité n'est donc pas due à une déperdition de temps dans les transitions jaunes.

2) **Monopolisation et famine de phase :** La Phase 2 capte à elle seule 80,8 % du temps vert (2910 s sur 3600 s), tandis que la Phase 3 (tourne-à-gauche secondaire) ne reçoit **aucun temps de vert** (0,0 s) sur l'ensemble de l'heure.

3) **Refoulement amont (*spillback*) :** En l'absence de vert sur la Phase 3, les véhicules engagés dans ce mouvement s'accumulent jusqu'à saturer physiquement l'approche d'entrée. Cette file continue empêche l'insertion de nouveaux véhicules générés par SUMO en périphérie du réseau, conduisant au blocage de **207 véhicules hors réseau**. Ce refoulement explique la baisse observée du nombre de véhicules terminés (580 au lieu de $\approx 889$).

Il convient de souligner que ce résultat s'observe sur cette géométrie spécifique et pour cette distribution de demande ; il ne constitue pas une invalidation de la théorie de Max-Pressure en réseau étendu, mais met en évidence la sensibilité de la règle de somme arithmétique sur carrefour isolé asymétrique.

### *C. Mécanisme de Régulation de l'Agent Double DQN*

L'agent Double DQN évite ce refoulement en raison de la structure de son critère d'optimisation.

Alors que Max-Pressure agit comme un sélecteur glouton à l'instant présent ($\arg\max_p P(p,t)$), la fonction de valeur du Double DQN intègre les récompenses futures actualisées par l'équation de Bellman (8) avec $\gamma = 0{,}99$. L'accumulation continue de véhicules à l'arrêt sur une approche non desservie entraîne une dégradation progressive du retour actualisé via la baisse de $r_t = \Delta W/100{,}0$.

En conséquence, la politique apprise par l'agent équilibre la desserte des deux axes directs (41,5 % pour la Phase 0 et 40,1 % pour la Phase 2) tout en insérant régulièrement des purges courtes sur la Phase 3 (18,3 % du temps vert, Figure 4). Cette stratégie maintient les files sous le seuil d'engorgement physique et assure un nombre nul de véhicules bloqués en amont ($N_{\text{block}} = 0$).

## VII. DISCUSSION ET PERSPECTIVES DE DÉPLOIEMENT

Sur le plan pratique, l'application d'un contrôle adaptatif local dans des environnements urbains tels que Thiès soulève des questions de faisabilité technique :

— **Instrumentation :** L'état d'entrée ($\mathbf{s}_t \in \mathbb{R}^{13}$) repose sur des agrégats par approche (files et densités). Une perspective réaliste d'instrumentation consisterait à employer une caméra grand angle en tête de mât associée à un modèle d'inférence visuelle légère, évitant ainsi le

coût d'installation et d'entretien des boucles magnétiques conventionnelles.

— **Charge de calcul :** Le modèle décisionnel (MLP $13 \to 64 \to 64 \to 4$) présente une empreinte calculatoire réduite. Son inférence peut s'envisager sur un processeur monocarte standard en bordure de route, le délai de calcul requis étant très largement inférieur à l'intervalle de décision de $5\,\mathrm{s}$.

Néanmoins, le passage de la simulation au terrain réel nécessite d'étudier la robustesse de la politique face aux occlusions visuelles partielles, aux variations de luminosité et aux incertitudes de détection.

## VIII. Conclusion

Cet article a présenté une évaluation comparative d'un contrôleur de feux adaptatif par Double DQN sur le carrefour principal de Thiès (Sénégal) sous Eclipse SUMO, face à un plan fixe à cycle de $78\,\mathrm{s}$, un régulateur actionné et l'algorithme Max-Pressure.

Sur cinq graines d'évaluation indépendantes de $3600\,\mathrm{s}$, l'agent Double DQN réduit le retard moyen de $50{,}7\,\%$ par rapport au plan fixe et maintient un débit achevé optimal. L'analyse microscopique de Max-Pressure Somme a permis d'isoler un phénomène de famine de phase menant au refoulement amont, que la politique apprise neutralise en intercalant des purges courtes sur l'approche secondaire.

Les travaux futurs porteront sur l'extension à la coordination de plusieurs intersections adjacentes via des architectures multi-agents, ainsi que sur l'évaluation de la résilience du modèle en présence de bruit de mesure sensoriel.

## Références


[1] A. Haydari and Y. Yılmaz, "Deep reinforcement learning for intelligent transportation systems : A survey," *IEEE Transactions on Intelligent Transportation Systems*, vol. 23, no. 1, pp. 11–30, 2022.

[2] F. V. Webster, "Traffic signal settings," *Road Research Technical Paper*, no. 39, Road Research Laboratory, HMSO, London, 1958.

[3] P. R. Lowrie, "SCATS, Sydney Co-ordinated Adaptive Traffic System : A traffic responsive method of controlling urban traffic," *Roads and Traffic Authority of New South Wales*, 1990.

[4] P. B. Hunt, D. I. Robertson, R. D. Bretherton, and R. I. Winton, "SCOOT : a traffic responsive method of coordinating traffic signals," *TRRL Laboratory Report*, no. 1014, Transport and Road Research Laboratory, Crowthorne, 1981.

[5] H. Wei, G. Zheng, H. Yao, and Z. Li, "IntelliLight : A reinforcement learning approach for intelligent traffic light control," in *Proc. 24th ACM SIGKDD Int. Conf. Knowledge Discovery & Data Mining (KDD)*, 2018, pp. 2496–2505.

[6] H. Wei, C. Chen, G. Zheng, K. Wu, V. Gayah, K. Xu, and Z. Li, "PressLight : Decentralized reinforcement learning via localized reward for traffic signal control," in *Proc. 25th ACM SIGKDD Int. Conf. Knowledge Discovery & Data Mining (KDD)*, 2019, pp. 1916–1925.

[7] C. Chen, H. Wei, N. Xu, G. Zheng, M. Yang, Y. Xiong, K. Xu, and Z. Li, "Toward a thousand lights : Decentralized deep reinforcement learning for large-scale traffic signal control," in *Proc. 34th AAAI Conf. Artificial Intelligence (AAAI)*, vol. 34, no. 01, 2020, pp. 3414–3421.

[8] C. Zhang, X. He, and G. Wang, "PDLight : A deep reinforcement learning traffic light control algorithm with pressure and dynamic light duration," *arXiv preprint arXiv :2009.13711*, 2020.

[9] H. Wei, G. Zheng, V. Gayah, and Z. Li, "Recent advances in reinforcement learning for traffic signal control : A survey of models and evaluation," *ACM SIGKDD Explorations Newsletter*, vol. 23, no. 2, pp. 12–25, 2021.

[10] K. Zhao, X. Zhai, and D. Guan, "Deep reinforcement learning for traffic signal control : A comprehensive review of algorithms, environments, and benchmark metrics," *IEEE Transactions on Intelligent Vehicles*, vol. 9, no. 3, pp. 4110–4128, 2024.

[11] C. M. Day, H. Li, L. Richardson, J. Howard, T. Platte, J. R. Sturdevant, and D. M. Bullock, "Detector-free optimization of traffic signal offsets with connected vehicle data," *Transportation Research Record*, vol. 2620, no. 1, pp. 52–60, 2017.

[12] P. Varaiya, "Max pressure control of a network of signalized intersections," *Transportation Research Part C : Emerging Technologies*, vol. 36, pp. 177–195, 2013.

[13] J. Lioris, R. Pedarsani, F. Y. Tascikaraoglu, and P. Varaiya, "Platooning for coupled car-following and maximum throughput at signalized intersections," *Transportation Research Part C : Emerging Technologies*, vol. 71, pp. 295–312, 2016.

[14] V. Mnih *et al.*, "Human-level control through deep reinforcement learning," *Nature*, vol. 518, no. 7540, pp. 529–533, 2015.

[15] W. Genders and S. Razavi, "Using deep reinforcement learning for traffic light control," *Transportation Research Record*, vol. 2620, no. 1, pp. 52–60, 2016.

[16] H. van Hasselt, A. Guez, and D. Silver, "Deep reinforcement learning with double Q-learning," in *Proc. 30th AAAI Conf. Artificial Intelligence (AAAI)*, 2016, pp. 2094–2100.